Práctica I

Aprendizaje Estadístico 2026/2027

Objetivo

El objetivo de esta práctica es aplicar de forma integrada las técnicas de aprendizaje estadístico estudiadas durante la primera parte del curso.

A diferencia de las prácticas realizadas en clase, cada estudiante (o grupo) deberá seleccionar un conjunto de datos de un repositorio público y justificar su elección.

El trabajo debe centrarse no sólo en la aplicación de las técnicas, sino también en la **interpretación de los resultados** y en las conclusiones que puedan extraerse del análisis.

1. Selección del conjunto de datos

El conjunto de datos deberá proceder preferentemente de repositorios públicos. Por ejemplo,

- UCI Machine Learning Repository. https://archive.ics.uci.edu/datasets
- OpenML.
- Kaggle. https://www.kaggle.com/datasets
- Data.gov. https://datos.gob.es/es/catalogo/conjuntos-datos

El conjunto de datos deberá contener un número suficiente de observaciones y varias variables que permitan plantear problemas de predicción o análisis.

2. Exploración de los datos (1pt)

Antes de construir los modelos, se debe realizar una exploración inicial de los datos. Se deberá incluir, al menos:

- una descripción de las variables;
- el número de observaciones y variables;
- una identificación de variables cuantitativas y cualitativas;
- visualizaciones relevantes;
- una discusión de posibles valores ausentes o anomalías.

No se trata de realizar una exploración exhaustiva, sino de identificar aquellos aspectos de los datos que sean relevantes para el análisis posterior.

3. Regresión lineal (2pt)

El conjunto de datos debe poder plantear un problema de regresión lineal. Debéis:

1. Seleccionar una variable respuesta cuantitativa.
2. Estudiar gráficamente su relación con algunos de los predictores.
3. Ajustar un modelo de regresión lineal simple.
4. Interpretar sus coeficientes.
5. Evaluar la calidad del ajuste.
6. Construir un modelo de regresión lineal múltiple. No hace falta considerar todas las variables, sino las que se consideren oportunas.
7. Interpretar los coeficientes del modelo múltiple.
8. Realizar predicciones para nuevas observaciones.

Comentad las diferencias entre los modelos simple y múltiple cuando sean relevantes.

4. Selección y regularización: Ridge y Lasso (2.5pt)

En esta partado, tenéis que aplicar las técnicas de regularización estudiadas en clase:

- Ridge;
- Lasso.

Debéis explicar brevemente por qué puede resultar conveniente utilizar regularización en el problema considerado.

Analizad el efecto del parámetro de regularización, utilizando validación cruzada para seleccionar un valor adecuado.

En el caso de Lasso, comentad qué variables son seleccionadas por el modelo y qué interpretación puede darse a este resultado.

Por último, añadid una comparación de los resultados obtenidos mediante regresión lineal, Ridge y Lasso. Es opcional incorporar Elastic Net y comparar los resultados obtenidos.

5. Análisis mediante PCA (2.5pt)

Se debe aplicar PCA a un conjunto de variables cuantitativas adecuado. Al menos, debe quedar reflejado:

- Un biplot y summary del modelo. Comentadlos.
- Justificación de la desviacin estndar de la primera componente principal.
- Tras la proporcin de varianza acumulada, cules son principalemente las componentes principales que reflejan la varianza de los datos?

No se pretende reproducir el desarrollo matemático de PCA, sino comprender qué información proporciona esta técnica y cómo puede utilizarse para explorar o resumir los datos.

6. Regresión logística (2pt)

Por último, se debe plantear un problema de clasificación binaria. Debéis:

1. identificar una variable respuesta binaria;

2. seleccionar las variables predictoras (una o varias);
3. ajustar un modelo de regresión logística;
4. interpretar los resultados;
5. evaluar el modelo mediante una matriz de confusión y las medidas estudiadas en clase;

Es opcional complementar el análisis utilizando LDA y comparar ambos modelos.

Evaluación de los modelos

A lo largo del trabajo, indicad cómo habéis separado los datos para entrenar y evaluar los modelos.

Cuando utilicéis validación cruzada, explicad brevemente para qué la habéis utilizado.

Si reserváis un conjunto de test, recordad que debe utilizarse únicamente para la evaluación final y no para decidir qué modelo o parámetros utilizar.

7. ¿Una o varias bases de datos?

Se recomienda realizar el trabajo utilizando **un único conjunto de datos**, siempre que sus características permitan aplicar de forma razonable las técnicas propuestas.

Sin embargo, si la base de datos seleccionada no permite plantear adecuadamente alguno de los problemas estudiados, se podrá utilizar un **segundo conjunto de datos**, justificando brevemente esta decisión.

Por ejemplo, la regresión logística requiere una variable respuesta binaria, por lo que podría ser necesario utilizar un segundo conjunto de datos.

8. Conclusiones

El trabajo deberá finalizar con una discusión de los principales resultados obtenidos.

- ¿Qué relaciones habéis encontrado?
- ¿Qué variables parecen ser más relevantes?
- ¿Qué diferencias existen entre los modelos considerados?

- ¿Qué información aporta PCA?
- ¿Qué limitaciones tiene el análisis?

Las conclusiones deberán estar justificadas a partir de los resultados obtenidos.

9. Entrega

Debéis adjuntar a la Tarea el fichero jupyter con código Python, junto al html o pdf.

El código debe ser claro y estar suficientemente comentado. Se valorará especialmente que el código utilizado sea coherente con las técnicas explicadas en clase y que las decisiones tomadas durante el análisis estén justificadas.

Recordad que la fecha límite es el 12 de noviembre.